

# 基于 Wolfe-Powell 准则的非精确一维步长搜索算法

Xiaoma

2023 年 1 月 6 日

## 问题描述

给定目标函数  $f(x)$ :

- 二维 Rosenbrock 函数:

$$f(x) = 100(x_1^2 - x_2)^2 + (x_1 - 1)^2$$

求解无约束优化问题:

$$\min_x f(x)$$

## 实验原理

### 拟牛顿法

#### 牛顿法

牛顿法的基本思想是利用目标函数的二次 Taylor 展开, 并将其极小化。

设  $f(x)$  是可微实函数,  $x^{(k)} \in \mathbb{R}^n$ , Hesse 矩阵  $\nabla^2 f(x^{(k)})$  正定, 在  $x^{(k)}$  附近用二次 Taylor 展开近似  $f$

$$q^{(k)}(s) = f(x^{(k)}) + \nabla f(x^{(k)})^T s + \frac{1}{2} s^T \nabla^2 f(x^{(k)}) s$$

其中  $s = x - x^{(k)}$ ,  $q^{(k)}(s)$  为  $f(x)$  的二次近似, 将上式右边极小化得

$$x^{(k+1)} = x^{(k)} - [\nabla^2 f(x^{(k)})]^{-1} \nabla f(x^{(k)})$$

在该公式中, 步长因子  $a_k = 1$ , 令  $G_k = \nabla^2 f(x^{(k)})$ ,  $g^{(k)} = \nabla f(x^{(k)})$ , 则原式可写为

$$x^{(k+1)} = x^{(k)} - G_k^{-1} g^{(k)}$$

显然, 牛顿法也可看成在椭球范数  $\|\cdot\|_{G_k}$  下的最速下降法, 对于  $f(x^{(k)} + s) \approx f(x^{(k)}) + g^{(k)\top} s$ ,  $s^{(k)}$  是极小化问题

$$\min \frac{g^{(k)\top} s}{\|s\|}$$

的解, 当采用  $l_2$  范数时

$$s^{(k)} = -g^{(k)}$$

所得方法是最速下降法, 当采用椭球范数  $\|\cdot\|_{G_k}$  时

$$s^{(k)} = -G_k^{-1} g^{(k)}$$

所得方法是牛顿法。

经典牛顿迭代法的运算步骤为

---

#### Algorithm 1: 牛顿法

---

**Input:** 初始点  $x_0$ , 阈值误差  $\varepsilon$

**Output:**  $x^{(k)}$ ,  $f(x^{(k)})$

(1) 初始化  $k=0$

(2) 计算  $g^{(k)} = \nabla f(x^{(k)})$ , 如果  $\|g^{(k)}\| < \varepsilon$ , 则停止迭代

(3) 解线性方程组  $s^{(k)} = -G_k^{-1} g^{(k)}$

(4) 更新  $x^{(k+1)} = x^{(k)} + s^{(k)}$ ,  $k = k + 1$ , 返回步骤 (2)

---

#### 拟牛顿法

牛顿法虽然收敛速度较快, 但计算 Hesse 矩阵的成本过大, 并且若矩阵不是正定的, 则牛顿法失效。

对  $\nabla f(x)$  在  $x^{(k)}$  出 Taylor 展开得到如下近似

$$\nabla f(x) = g^{(k)} + H_k(x - x^{(k)})$$

令  $x = x^{(k+1)}$  即可得到  $g^{(k+1)} - g^{(k)} = H_k(x^{(k+1)} - x^{(k)})$

记  $y^{(k)} = g^{(k+1)} - g^{(k)}, \delta_k = x^{(k+1)} - x^{(k)}$

$$y^{(k)} = H_k \delta_k$$

称为拟牛顿条件

## DFP 法

设对称秩二矫正为

$$H_{k+1} = H_k + a u u^T + b v v^T$$

令拟牛顿条件满足，则

$$H_k y^{(k)} + a u u^T y^{(k)} + b v v^T y^{(k)} = s^{(k)}$$

这里  $u$  和  $v$  并不唯一确定，但  $u$  和  $v$  的明显选择是

$$u = s^{(k)} \quad v = H_k y^{(k)}$$

确定出

$$a = 1/y^{(k)} u^T = 1/s^{(k)T} y^{(k)} b = -1 v^T / y^{(k)} = -1/y^{(k)T} H_k y^{(k)}$$

因此

$$H_{k+1} = H_k + \frac{s^{(k)} s^{(k)T}}{s^{(k)T} y^{(k)}} - \frac{H_k y^{(k)} y^{(k)T} H_k}{y^{(k)T} H_k y^{(k)}}$$

这个公式称为 DFP 公式。DFP 法的运算步骤为

## BFGS

类似的，可以得到关于  $B_k$  的对称秩二矫正公式

$$B_{k+1}^{(BFGS)} = B_k + \frac{\mathbf{y}^{(k)} \mathbf{y}^{(k)T}}{\mathbf{y}^{(k)T} \mathbf{s}^{(k)}} - \frac{B_k \mathbf{s}^{(k)} \mathbf{s}^{(k)T} B_k}{\mathbf{s}^{(k)T} B_k \mathbf{s}^{(k)}}$$

---

**Algorithm 2:** DFP
 

---

**Input:** 初始点  $x_0$ , 阈值误差  $\varepsilon$

**Output:**  $x^{(k)}, f(x^{(k)})$

- (1) 初始化  $H_0 = I, k = 0$
  - (2) 计算搜索方向:  $d^{(k)} = -H_k \nabla f(x^{(k)})$ , 如果  $\|g^{(k)}\| < \varepsilon$ , 停止迭代
  - (3) 一维搜索确定步长  $\alpha_k$ , 令  $x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)}$
  - (4) 令  $\mathbf{s}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}, \mathbf{y}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$ , 当  $\mathbf{s}^{(k)T} \mathbf{y}^{(k)} > 0$ , 作更新  $H_{k+1} = H_k + \frac{\mathbf{s}^{(k)} \mathbf{s}^{(k)T}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} - \frac{H_k \mathbf{y}^{(k)} \mathbf{y}^{(k)T} H_k}{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}}$ 。置  $k = k + 1$ , 返回步骤 (2)
- 

$H_k$  的 BFGS 校正公式为

$$H_{k+1}^{(BFGS)} = H_k + \left( 1 + \frac{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} \right) \frac{\mathbf{s}^{(k)} \mathbf{s}^{(k)T}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} - \frac{H_k \mathbf{y}^{(k)} \mathbf{s}^{(k)T} + \mathbf{s}^{(k)} \mathbf{y}^{(k)T} H_k}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}}.$$

BFGS 法的运算步骤为

---

**Algorithm 3:** BFGS
 

---

**Input:** 初始点  $x_0$ , 阈值误差  $\varepsilon$

**Output:**  $x^{(k)}, f(x^{(k)})$

- (1) 初始化  $H_0 = I, k = 0$
  - (2) 计算搜索方向:  $d^{(k)} = -H_k \nabla f(x^{(k)})$ , 如果  $\|g^{(k)}\| < \varepsilon$ , 停止迭代
  - (3) 一维搜索确定步长  $\alpha_k$ , 令  $x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)}$
  - (4) 令  $\mathbf{s}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}, \mathbf{y}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$ , 作更新  $H_{k+1}^{(BFGS)} = H_k + \left( 1 + \frac{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} \right) \frac{\mathbf{s}^{(k)} \mathbf{s}^{(k)T}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} - \frac{H_k \mathbf{y}^{(k)} \mathbf{s}^{(k)T} + \mathbf{s}^{(k)} \mathbf{y}^{(k)T} H_k}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}}$ 。置  $k = k + 1$ , 返回步骤 (2)
-

## 非精确一维步长搜索

### 非精确一维搜索

找出满足某些适当条件的粗略近似解作为步长，提升算法的整体计算效率

**Wolfe-Powell conditions :**

$$\varphi(\alpha) \leq \varphi(0) + \rho\alpha\varphi'(0)$$

$$\varphi'(\alpha) \geq \sigma\varphi'(0)$$

其中  $\rho \in (0, \frac{1}{2})$ ,  $\sigma \in (\rho, 1)$  是固定参数。

设  $\hat{\alpha}_k$  是使得  $f(x^{(k)} + \alpha d^{(k)}) = f(x^{(k)})$  的最小正数  $\alpha$

### 基于 Wolfe-Powell 准则的非精确一维步长搜索

- (1) 给定初始一维搜索区间  $[0, \bar{\alpha}]$ , 以及  $\rho \in (0, \frac{1}{2})$ ,  $\sigma \in (\rho, 1)$ . 计算  $\varphi_0 = \varphi(0) = f(x^{(k)})$ ,  $\varphi'_0 = \varphi'(0) = \nabla f(x^{(k)})^T d^{(k)}$ . 并令  $a_1 = 0, a_2 = \bar{\alpha}, \varphi_1 = \varphi_0, \varphi'_1 = \varphi'_0$ . 选取适当的  $\alpha \in (a_1, a_2)$ .
- (2) 计算  $\varphi = \varphi(\alpha) = f(x^{(k)} + \alpha d^{(k)})$ . 若  $\varphi(\alpha) \leq \varphi(0) + \rho\alpha\varphi'(0)$ , 则转到第 (3) 步。否则, 由  $\varphi_1, \varphi'_1, \varphi$  构造二次插值多项式  $p^{(1)}(t)$ , 并得其极小点  $\hat{\alpha}$ . 令  $a_2 = \alpha, \alpha = \hat{\alpha}$ , 重复第 (2) 步.
- (3) 计算  $\varphi' = \varphi'(\alpha) = \nabla f(x^{(k)} + \alpha d^{(k)})^T d^{(k)}$ . 若  $\varphi'(\alpha) \geq \sigma\varphi'(0)$ , 则输出  $\alpha_k = \alpha$ , 并停止搜索. 否则由  $\varphi, \varphi', \varphi'_1$  构造两点二次插值多项式  $p^{(2)}(t)$ , 并求得极小点  $\hat{\alpha}$ . 令  $a_1 = \alpha, \alpha = \hat{\alpha}$ , 返回第 (2) 步.

## 数据说明

二维 Rosenbrock 函数

## 程序输入输出说明

输入 1、2 选择 DFP/BFGS, 然后输入初始点。

输出值为迭代次数与最优解

## 程序测试结果

DFP	epoch	x1, x2	f
0 0	17	0.9999999986994 0.9999999981660	6.055373455850762e-17
0.5 0.5	16	1.00000001203758 1.0000000247276	1.8747613102236447e-16
-1 1	1	1.0 1.0	0.0
2 -3	37	0.99999999503545 0.99999999346	1.176336523561564e-15
-100 150		无法收敛	
BFGS	epoch	x1, x2	f
0 0	18	0.99999999786 0.99999999574	4.635405677357143e-18
0.5 0.5	15	0.9999999995 0.9999999990	2.4722121607796934e-19
-1 1	1	1.0 1.0	0.0
2 -3	26	1.00000002922187 1.000000058506	8.543076984615268e-16
-100 150	271	0.99999999993 0.9999999999	4.539167488746724e-19

## 分析总结

不同的初始点也可能产生截然不同的结果，甚至无法收敛。  
经过测试发现，BFGS 法具有比 DFP 法更稳定的数值。